DATA INFRASTRUCTURE

# データ基盤勉強会

Databricks × dbt で体験するメダリオンアーキテクチャ

座学 30分 + ハンズオン 60分

AGENDA

# 本日の流れ

| | | |
|---|---|---|
| 01 | **データ基盤とは**<br>基本概念・メダリオン・DEの業務 | 20 min |
| 02 | **Databricks とは**<br>レイクハウスの概要と今日使う機能 | 8 min |
| 03 | **dbt とは**<br>SQLを資産化するツール | 8 min |
| 04 | **今日やること全体像**<br>アーキテクチャとステップ | 9 min |
| 05 | **ハンズオン**<br>Bronze→Silver→Gold→ダッシュボード | 60 min |

AGENDA

# 事前準備

- ✓ databricks free editionの登録
- ✓ dbt cloudの登録 (個人なら無料です)
- ✓ 下記リポジトリのcloneおよび自分のGithubへのpush
  - https://github.com/AbeTai/databricks-dbt-handson

PART 01

# データ基盤とは

*分析で触るテーブルは、誰がどう作っているのか？*

1-1 BASICS

# データ基盤とは

データを 集めて・整えて・使えるようにする 仕組み

SOURCE

## ソース

アプリDB / SaaS / ログ
業務で発生する生データ

→

TRANSFORM

## 加工

整形・結合・集計
分析しやすい形に変換

→

CONSUME

## 分析・活用

BI / 機械学習 / API
ビジネスに還元

*この一連の仕組み全体を「データ基盤」と呼ぶ*

1-2 PRODUCTS

# データ基盤の主要プロダクト

## クラウドDWH

各クラウドベンダーの主力DWH

| | |
|---|---|
| **Amazon Redshift** | AWS |
| **Google BigQuery** | GCP |
| **Microsoft Fabric** | Azure |

## マルチクラウド

クラウド横断で使えるレイクハウス

| | |
|---|---|
| **Snowflake** | DWH寄り |
| **Databricks** | レイクハウス |

今日は Databricks を使います

1-3 ETL / ELT

# データ加工プロセスの基本

**E**

### Extract

ソースからデータを取得する

**T**

### Transform

必要な形に加工・整形する

**L**

### Load

DWHに格納する

### 最近の主流は ELT

先にDWHへLoad → DWHの計算資源でTransform。
クラウドDWHの性能向上で現実的になった方式。Databricks + dbt もこのパターン。

1-4 MEDALLION

# メダリオンアーキテクチャ

| | |
|---|---|
| **BRONZE**<br>ブロンズ層<br>*生データ* | ソースをそのまま取り込む。加工は最小限。トレーサビリティが目的。 |
| **SILVER**<br>シルバー層<br>*クレンジング済み* | 型変換・カラム名統一・重複除去など。実務の主戦場。 |
| **GOLD**<br>ゴールド層<br>*ビジネス指標* | 集計・結合で分析目的別のテーブル。BIはここを参照。 |

*加工が進むほど「分析しやすく」なる3層構造*

1-5 ARCHITECTURE

# 典型的なアーキテクチャ例

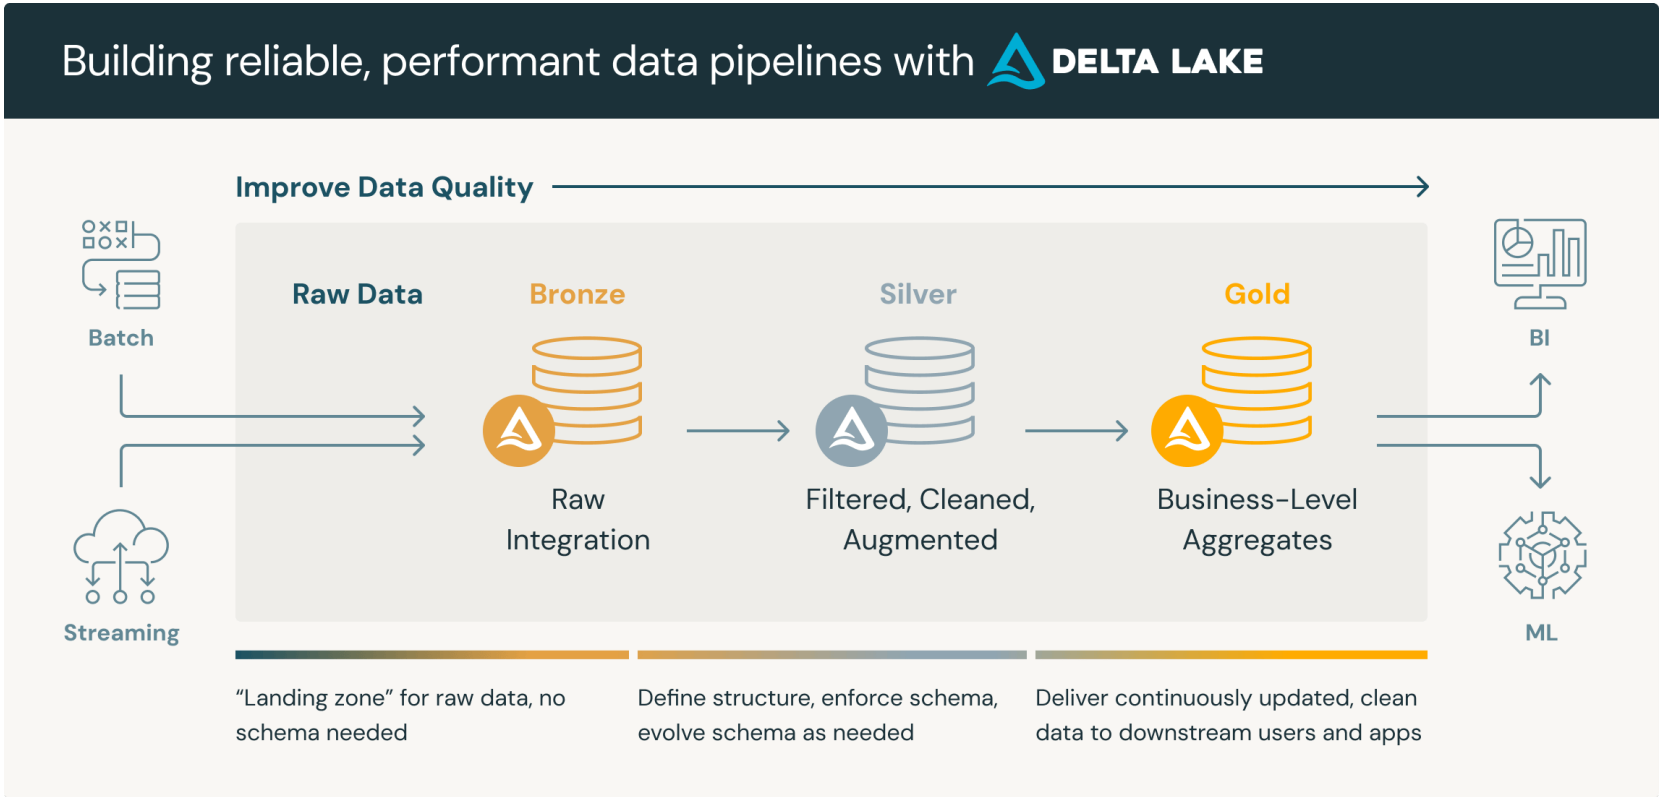


MLはSilverをソースとすることもある(運用次第)

1-6 DATA ENGINEER

# データエンジニアの業務

### テーブル設計・作成

ソースに応じたスキーマ設計、命名、パーティション戦略。分析しやすい構造を考える。

### パイプライン開発

ETL/ELTジョブの実装、スケジューリング、エラー処理、再実行設計。

### メタデータ整備

テーブル・カラムの説明、データテスト、リネージ、利用者への周知。

1-7 END-TO-END

# 実務での一連の流れ

1
**SQL を書く**
dbtモデルを開発

2
**GitHub へ Push**
PRを出してレビュー

3
**CI/CD が走る**
自動テスト・lint

4
**Databricks へ連携**
本番環境に反映

5
**Daily でジョブ実行**
dbt run + test

6
**BI で可視化**
ダッシュボード

**今日のハンズオンはこの流れを縮小版で体験します**

「SQL書く → GitHub → dbt Cloud → Databricks → ダッシュボード」を60分で一周

PART 02

# Databricks とは

*データレイクハウスのデファクト*

2-1 OVERVIEW

# Databricks の概要

## データレイクハウス

DWH（構造化データの分析）と データレイク（多様な形式の保存）を統合したアーキテクチャ

### Apache Spark ベース

大規模データを分散処理。ペタバイト級にもスケール。

### SQL と Python を両方サポート

データエンジニアもサイエンティストも同じ基盤で作業。

### Unity Catalog

カタログ・スキーマ・テーブルで権限・メタデータを一元管理。

2-2 FEATURES

# 今日使う機能

### Catalog Explorer

samples カタログ の tpch スキーマからプリセットデータにアクセス。

### SQL Warehouse

SQLクエリの実行エンジン。dbt Cloudから接続する先もここ。

### Dashboard

ノーコードでグラフ・フィルタを配置。Goldテーブルを可視化。

Databricks Free Edition を使用。事前にサインアップ＆SQL Warehouseを用意してきてください。

PART 03

# dbt とは

*SQLをソフトウェア開発の作法で書く*

3-1 OVERVIEW

# dbt の概要

## SQLをそのままデータパイプラインにできるツール = ETL/ELTが簡単に出来るツール

「T（Transform）」に特化。SQLを書くだけで依存関係・テスト・ドキュメントが手に入る。

### モデル = .sql ファイル1つ = テーブル（またはビュー）1つ

```
-- models/silver/silver_orders.sql

SELECT
    o_orderkey AS order_id,
    o_custkey  AS customer_id,
    o_totalprice AS total_price
FROM {{ ref('bronze_orders') }}
```

*{{ ref() }} で依存関係を宣言 → dbtが実行順序を自動解決*

3-2 BENEFITS

# dbt の3大メリット

### テスト

not_null / unique / accepted_values など、
YAMLで宣言するだけでデータ品質を担保。

### ドキュメント

モデル説明・カラム定義・リネージ図を自
動生成。チーム全体の知識資産に。

### バージョン管理

ただのSQL/yamlファイルなのでGitと
相性抜群。PR・レビュー・CI/CDが成立。

***結果：SQLがチーム資産になり、壊れにくくなる***

# dbt Cloud について

## dbt Cloud = dbtのマネージドサービス

**GitHub 連携**
リポジトリと自動同期

**ジョブのスケジュール実行**
日次・時次で dbt run

**実行ログ・履歴管理**
GUIで失敗を追跡

**IDE（ブラウザ上）**
SQL書いてそのまま実行

**今日の連携**

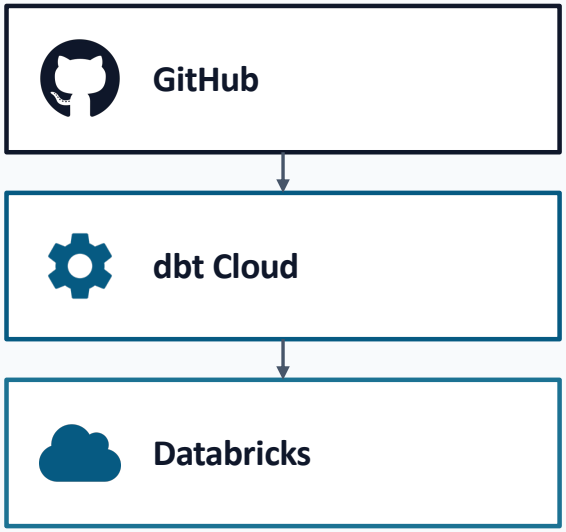


*Push すれば dbt Cloud 経由で Databricks に反映*

PART 04

# 今日やること全体像

*tpch データから ダッシュボードまで*

4-1 TODAY'S ARCH

# 今日作るアーキテクチャ

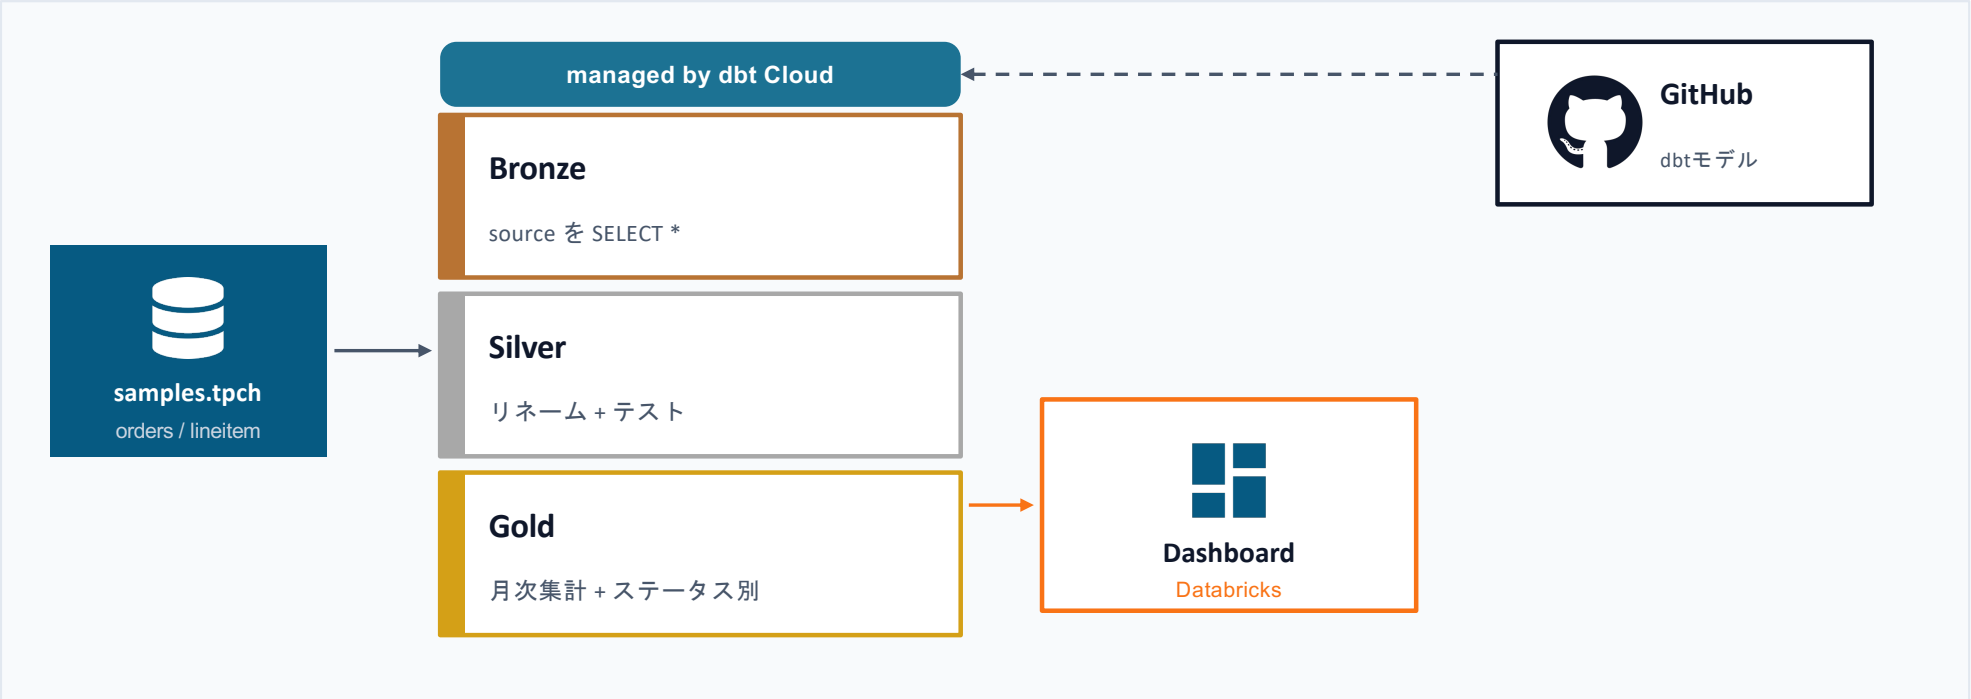


*データの流れ：samples.tpch → Bronze → Silver → Gold → Dashboard*

4-2 STEPS

# ハンズオン 7ステップ

| | | | |
|---|---|---|---|
| 01 | GitHub クローン・確認 | dbtプロジェクトをローカルへ | 5 min |
| 02 | dbt Cloud × Databricks 接続 | profiles の接続情報確認 | 5 min |
| 03 | Bronze モデル実行 | samples.tpch を取り込む | 10 min |
| 04 | Silver モデル + テスト | 整形 + dbt test | 15 min |
| 05 | Gold モデル実行 | 集計テーブル2つ | 10 min |
| 06 | dbt Cloud ジョブ設定 | スケジュール実行 | 5 min |
| 07 | Databricks ダッシュボード | グラフ2種類を配置 | 10 min |

*各ステップの最後に、アーキテクチャ図で「今どこにいるか」を確認します*

LET'S BUILD

# ハンズオンスタート

手を動かして、データ基盤の一連を体験しましょう

# ハンズオン 内容

- 

**詳細はHANDSON_STEPS.mdを確認してください**